

**AGENTE CONVERSACIONAL PARA ADMISIÓN
Y NIVELACIÓN DE LA UNIVERSIDAD DE GUAYAQUIL**

Grupo 10

Alvarez Echeverria Matthew Alejandro

Procesamiento De Lenguaje Natural

UNIVERSIDAD DE GUAYAQUIL

FACULTAD DE CIENCIAS MATEMÁTICAS Y FÍSICAS

Angel Eduardo Cuenca Ortega

10 Julio 2026

1. Introducción

Los procesos de admisión y nivelación de la Universidad de Guayaquil (UG) generan un alto volumen de consultas repetitivas por parte de los aspirantes: requisitos de inscripción, fechas de registro y matrícula, creación de cuentas, aprobación de asignaturas, cupos y aceptación de carreras. Esta información se encuentra dispersa en sitios oficiales, guías y publicaciones en redes, lo que dificulta su consulta ágil.

El presente proyecto propone aplicar técnicas clásicas de Procesamiento de Lenguaje Natural (PLN) para construir un agente conversacional (chatbot) que responda, en español, preguntas frecuentes sobre admisión y nivelación de la UG, a partir de información de fuentes oficiales. El sistema se basa en la detección de intenciones mediante TF-IDF y similitud coseno, con recuperación de respuestas predefinidas.

2. Diseño de Intenciones y Entidades

El sistema define 21 intenciones principales almacenadas en `data/intents.json`. Cada intención contiene un conjunto de patrones (frases de usuario) y una o varias respuestas predefinidas. Las intenciones cubren:

- Proceso de admisión: registro nacional, inscripción/postulación, evaluación, asignación y aceptación de cupos.
- Proceso de nivelación: requisitos, matrícula, evaluación, plataformas virtuales.
- Información general: oferta académica, costos/aranceles, gratuidad, tipos de matrícula, transferencia, requisitos para extranjeros, políticas de cupos.
- Interacción: saludo, despedida, contacto.
- Fallback: respuesta para consultas no reconocidas.

Las entidades se extraen mediante expresiones regulares y búsqueda por diccionario en `entity_extractor.py`: fechas, cédulas (10 dígitos), montos en dólares, porcentajes, nombres de 57 carreras de la UG, y términos de procesos específicos como "curso de nivelación", "cupo aceptado", "matrícula ordinaria", etc.

3. Arquitectura del Agente

La arquitectura del agente sigue un pipeline modular con los siguientes componentes:

1. Preprocesamiento (preprocess.py): Conversión a minúsculas, normalización de acentos, eliminación de puntuación, tokenización, eliminación de stopwords (NLTK) y stemming (Snowball).
2. Vectorización (vectorizer.py): Representación TF-IDF con unigramas y bigramas usando TfidfVectorizer de scikit-learn. Se genera una matriz dispersa de las frases de entrenamiento.
3. Clasificación (classifier.py): Cálculo de similitud coseno entre la consulta y todas las frases de entrenamiento. Se selecciona la intención con mayor similitud. Si supera el umbral de 0.35, se retorna la respuesta; caso contrario, se retorna el fallback.
4. Extracción de entidades (entity_extractor.py): Identificación de fechas, cédulas, montos, porcentajes, carreras y términos de procesos mediante regex y búsqueda por diccionario.
5. Agente central (agent.py): Coordina el pipeline: preprocesamiento → clasificación → extracción de entidades → respuesta.
6. Interfaz (app.py): Interfaz web con Gradio para interacción en tiempo real.

4. Justificación de Decisiones de Diseño

a) TF-IDF vs bolsa de palabras con conteos simples

TF-IDF pondera la frecuencia de un término por su importancia inversa en el corpus. El factor IDF reduce el peso de palabras comunes (como "universidad" o "estudiante") y aumenta el peso de términos discriminativos (como "nivelación", "cupos", "aranceles"). Esto permite diferenciar mejor entre intenciones que comparten vocabulario común. En nuestro proyecto, palabras como "matrícula" aparecen en múltiples intenciones, pero TF-IDF ayuda a identificar los términos contextualmente relevantes.

b) Similitud coseno vs distancia euclidiana

La similitud coseno mide el ángulo entre dos vectores, no su magnitud. Esto la hace invariable a la longitud del documento. La distancia euclidiana sí depende de la longitud: una frase larga estaría más lejos de una corta aunque tengan el mismo significado. En nuestro caso, consultas como "cómo me matriculo" (4 palabras) y "qué necesito para matricularme en nivelación" (7 palabras) deben compararse independientemente de su longitud.

c) Preprocesamiento antes de vectorizar

El preprocesamiento (stemming y eliminación de stopwords) reduce el vocabulario y agrupa formas flexionadas. Por ejemplo, "inscripción", "inscribirme" e "inscribiendo" se reducen a la raíz "inscrib", mejorando la coincidencia. Las stopwords como "el", "la", "de" no aportan significado y se eliminan para reducir ruido en la representación TF-IDF.

d) Umbral de confianza y fallback

El umbral de 0.35 se seleccionó empíricamente probando diferentes valores (0.25, 0.30, 0.35, 0.40) y evaluando el balance entre falsos positivos y falsos negativos. Sin umbral, cualquier consulta se clasificaría en la intención más cercana, incluso si la similitud es muy baja, generando respuestas incorrectas. El fallback informa al usuario que su consulta no fue reconocida y sugiere reformularla.

e) JSON separado del código

Almacenar intenciones, utterances y respuestas en JSON permite:

- Modificar patrones y respuestas sin tocar el código fuente.
- Facilitar la adición de nuevas intenciones.
- Mantener separación de responsabilidades: datos vs lógica.
- Permitir que múltiples componentes (vectorizer, agent) accedan a los mismos datos.

f) Manejo de entradas problemáticas con try-except

El agente maneja entradas problemáticas en múltiples niveles:

- Consulta vacía o en blanco: se retorna fallback sin procesar.
- Texto sin tokens después de preprocesamiento: se retorna fallback.
- Similitud por debajo del umbral: se retorna fallback.

Esto se implementa en agent.py con validaciones antes de cada paso del pipeline, evitando que el agente se detenga ante entradas inválidas.

5. Resultados de Evaluación

El agente se evaluó con un conjunto de 28 consultas de prueba, incluyendo variaciones lingüísticas, errores tipográficos y preguntas ambiguas (OOD). Los resultados obtenidos:

- Accuracy: 92.86%
- F1-Macro: 95.83%
- Correctas: 26/28

Los 2 errores corresponden a consultas OOD que contienen vocabulario del dominio ("universidad", "estudiante", "cuesta") pero que no son sobre admisión/nivelación. Esta es una limitación inherente de TF-IDF, que compara términos sin comprender significado.

Limitaciones observadas:

1. Vocabulario OOD: consultas con palabras del dominio fuera de contexto pueden clasificarse incorrectamente.
2. Dependencia de patrones: el sistema solo reconoce intenciones para las cuales tiene patrones de entrenamiento.
3. Sin contexto: no mantiene estado entre turnos conversacionales.
4. Sin comprensión semántica: sinónimos o paráfrasis no entrenadas pueden fallar.

6. Conclusiones

El agente conversacional demuestra que técnicas clásicas de PLN como TF-IDF y similitud coseno son suficientes para construir un chatbot funcional en un dominio específico. El sistema logra un accuracy del 92.86% con solo 21 intenciones entrenadas, cubriendo los temas principales de admisión y nivelación de la UG.

Las principales limitaciones están relacionadas con la falta de comprensión semántica profunda y la incapacidad de manejar consultas fuera del dominio. Sin embargo, para el propósito de un asistente virtual de FAQ en un dominio restringido, el enfoque demostrado es efectivo y replicable.

Los aprendizajes incluyen la importancia del preprocesamiento de texto, la selección adecuada del umbral de confianza, y la necesidad de un conjunto de prueba variado que incluya consultas adversariales para una evaluación realista.

Referencias

Coordinación de Admisión y Nivelación. (s.f.). Portal oficial de admisión Universidad de Guayaquil. <https://admision.ug.edu.ec/admision/>

Coordinación de Admisión y Nivelación. (s.f.). Nivelación Universidad de Guayaquil. <https://admision.ug.edu.ec/nivelacion/>

Coordinación de Admisión y Nivelación. (s.f.). Oferta académica UG. <https://admision.ug.edu.ec/oferta-ug/>

Coordinación de Admisión y Nivelación. (s.f.). Reglamento de admisión de la Universidad de Guayaquil 2023 (Reformado) [PDF]. Universidad de Guayaquil.

Coordinación de Admisión y Nivelación. (s.f.). Reglamento de matrículas, aranceles y derechos de la Universidad de Guayaquil 2023 (Reformado) [PDF]. Universidad de Guayaquil.

alaU. (s.f.). Todo lo que necesitas saber para ingresar a la Universidad de Guayaquil. Blog alaU. <https://blog.alau.org/todo-lo-que-necesitas-saber-para-ingresar-a-la-universidad-de-guayaquil/>